

Comparative Analysis of BERTopic Hyperparameter Optimization Using Artificial Bee Colony and Grid Search

Analisis Komparatif Optimisasi Hyperparameter BERTopic Menggunakan Artificial Bee Colony dan Grid Search

Joshua Bryan Wijaya¹, Mhd Haekal Hakim², Zifa Aura Rahman³, Muthi'ah Iffa Karimah⁴, Sachnaz Desta Oktarina⁵, Bagus Sartono⁶, Rahma Anisa⁷, Akbar Rizki⁸, Indra Mahib Zuhair Riyanto⁹

^{1,2,3,4,5,6,7,8,9} IPB University

Email: ⁵sachnazdes@apps.ipb.ac.id

Abstract

Economic growth is an important indicator for assessing a country's economic condition and is frequently discussed on social media. This study aims to analyze public perceptions of Indonesia's economic growth in the first quarter of 2026 based on YouTube comments using BERTopic and to compare the performance of Artificial Bee Colony (ABC) and Grid Search for hyperparameter optimization. The dataset consisted of 5,089 comments collected from 10 YouTube channels discussing Indonesia's economic growth. The preprocessing stage included text cleaning, normalization, tokenization, stopword and emoticon removal, and conversion of nonverbal expressions into textual representations to preserve contextual information. The optimized hyperparameters were *n_neighbors* in UMAP and *min_cluster_size* in HDBSCAN, using a weighted objective function with 0.7 for topic coherence and 0.3 for topic diversity. The results revealed a clear trade-off between the two methods. Grid Search achieved the best performance with an objective score of 0.7101, a coherence score of 0.5858, a diversity score of 1.0000, and the lowest outlier rate of 3.48%. Meanwhile, ABC obtained an objective score of 0.6649 with an outlier rate of 5.42%. Both methods generated a consistent topic structure consisting of financial activity and public skepticism topics. In terms of efficiency, ABC produced competitive results with computational time approximately 5.5 times faster than Grid Search, indicating its potential as an efficient alternative for BERTopic hyperparameter optimization.

Keywords: Economic growth, HDBSCAN, Topic Modeling, UMAP, YouTube.

Abstrak

Pertumbuhan ekonomi merupakan salah satu indikator penting dalam menilai kondisi perekonomian suatu negara dan sering menjadi topik diskusi masyarakat di media sosial. Penelitian ini bertujuan untuk menganalisis persepsi masyarakat terhadap pertumbuhan ekonomi Indonesia pada Kuartal-I tahun 2026 berdasarkan komentar YouTube menggunakan BERTopic serta membandingkan kinerja *Artificial Bee Colony* (ABC) dan *Grid Search* dalam optimasi *hyperparameter*. Data penelitian terdiri atas 5089 komentar yang dikumpulkan dari 10 kanal YouTube yang membahas pertumbuhan ekonomi Indonesia. Tahap pra-pemrosesan meliputi pembersihan teks, normalisasi, tokenisasi, penghapusan *stopword* dan emotikon, serta konversi ekspresi nonverbal ke dalam representasi teks.

untuk mempertahankan informasi kontekstual. *Hyperparameter* yang dioptimasi meliputi *n_neighbors* pada UMAP dan *min_cluster_size* pada HDBSCAN dengan menggunakan fungsi objektif berupa agregasi linear berbobot (*weighted sum*) sebesar 0.7 untuk *topic coherence* dan 0.3 untuk *topic diversity*. Hasil penelitian menunjukkan bahwa kedua metode memiliki *trade-off* yang jelas. *Grid Search* menghasilkan performa terbaik dengan *objective score* sebesar 0.7101, *coherence score* sebesar 0.5858, *diversity score* sebesar 1.0000, serta tingkat *outlier* terendah sebesar 3.48%. Sementara itu, ABC menghasilkan *objective score* sebesar 0.6649 dengan tingkat *outlier* sebesar 5.42%. Meskipun demikian, kedua metode menghasilkan struktur topik yang konsisten, yaitu topik aktivitas finansial dan topik skeptisisme publik. Dari sisi efisiensi, ABC mampu memperoleh solusi yang kompetitif dengan waktu komputasi sekitar 5.5 kali lebih cepat dibandingkan *Grid Search*. Temuan ini menunjukkan bahwa *Grid Search* unggul dalam kualitas solusi, sedangkan ABC menawarkan efisiensi komputasi yang lebih baik sehingga berpotensi menjadi alternatif yang efektif untuk optimasi *hyperparameter* BERTopic.

Kata kunci: HDBSCAN, Pertumbuhan Ekonomi , *Topic Modeling*, UMAP, YouTube.

1. PENDAHULUAN

Optimisasi merupakan tahapan penting dalam pemodelan *machine learning* yang bertujuan menemukan kombinasi *hyperparameter* terbaik untuk menghasilkan performa model yang optimal, mengingat pemilihan *hyperparameter* yang tepat dapat memberikan dampak signifikan terhadap kualitas model (Yang & Shami, 2020). Salah satu metode yang umum digunakan adalah *Grid Search*, yaitu pendekatan *exhaustive search* yang mengevaluasi seluruh kombinasi *hyperparameter* pada ruang pencarian (*search space*) yang telah ditentukan. Pendekatan ini memungkinkan *Grid Search* menemukan kombinasi *hyperparameter* terbaik sekaligus menjamin diperolehnya optimum global pada ruang pencarian yang dievaluasi karena seluruh kandidat solusi diperiksa secara sistematis, sehingga sering digunakan sebagai metode pembanding (*baseline*) dalam penelitian optimasi *hyperparameter*. Namun, jumlah evaluasi yang harus dilakukan meningkat secara eksponensial seiring bertambahnya jumlah *hyperparameter* dan kandidat nilainya, sehingga tidak efisien untuk masalah berukuran besar dan biaya komputasi yang dibutuhkan menjadi tinggi (Bergstra & Bengio, 2012; Feurer & Hutter, 2019; Ali *et al.*, 2023).

Sebagai alternatif yang lebih adaptif, algoritma metaheuristik berbasis *swarm intelligence* menawarkan pendekatan pencarian yang lebih efisien dengan cara mengeksplorasi ruang solusi secara cerdas tanpa perlu mengevaluasi seluruh kombinasi yang ada. Salah satunya adalah *Artificial Bee Colony* (ABC), algoritma yang mengadaptasi perilaku koloni lebah madu dalam mencari sumber makanan. ABC terbukti mampu menjaga keragaman populasi pada fase eksplorasi sekaligus menghindari jebakan optimum lokal, sehingga lebih unggul secara komputasi dibandingkan *Grid Search* (Karaboga & Basturk, 2007; Haron *et al.*, 2025).

Salah satu domain yang membutuhkan optimisasi *hyperparameter* adalah pemodelan topik berbasis *transformers*, khususnya BERTopic (*Bidirectional Encoder Representations from Transformers Topic Modeling*). BERTopic merupakan metode pemodelan topik yang diperkenalkan oleh Grootendorst (2022) dengan memanfaatkan representasi vektor kontekstual dari model BERT, yang kemudian diikuti proses reduksi dimensi menggunakan *Uniform Manifold Approximation and Projection* (UMAP) dan klusterisasi menggunakan *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN) (Chakkarwar *et al.*, 2026). Kualitas topik yang dihasilkan sangat sensitif terhadap kombinasi *hyperparameter*, terutama *n_neighbors* pada UMAP dan *min_cluster_size* pada HDBSCAN, di mana kombinasi yang tidak tepat dapat menghasilkan topik yang tidak koheren atau proporsi *outlier* yang tinggi (Terragni *et al.*, 2021).

Relevansi BERTopic semakin nyata dalam konteks analisis opini publik berbasis media sosial. Kemajuan teknologi menjadikan komentar daring sebagai cerminan dinamika masyarakat yang kaya informasi, termasuk respons publik terhadap isu ekonomi makro. Pertumbuhan ekonomi Indonesia sebesar 5.61% pada Kuartal-I 2026 (BPS, 2026) menjadi salah satu isu yang memantik diskusi publik yang luas di platform seperti YouTube, sehingga berpotensi menjadi korpus teks yang representatif untuk dianalisis menggunakan NLP (*Natural Language Processing*). Isu pertumbuhan ekonomi Indonesia dipilih karena merupakan salah satu indikator utama kondisi perekonomian nasional yang selalu menjadi perhatian pemerintah, pelaku usaha, dan masyarakat. Pengumuman pertumbuhan ekonomi Indonesia Kuartal I 2026 memicu beragam tanggapan publik di media sosial, khususnya YouTube, sehingga menarik untuk dianalisis guna mengidentifikasi topik-topik utama yang berkembang dalam opini masyarakat.

Sejumlah penelitian terdahulu telah mengonfirmasi urgensi optimisasi *hyperparameter* dalam pemodelan BERTopic. Borčín dan Jose (2024) melakukan studi reproduisibilitas dan analisis pengaruh parameter pada BERTopic, yang menunjukkan bahwa pemilihan model *embedding* dan skema pembobotan kata (*term weighting*) berpengaruh signifikan terhadap kualitas topik yang dihasilkan. Selanjutnya, Murugaraj dkk. (2025) menerapkan kerangka Hyperopt berbasis algoritma *Tree-structured Parzen Estimator* (TPE), yaitu metode optimisasi *hyperparameter* berbasis probabilistik yang memanfaatkan hasil evaluasi sebelumnya untuk mengarahkan proses pencarian ke wilayah yang diperkirakan menghasilkan nilai fungsi objektif lebih baik. Hasil penelitian tersebut menunjukkan bahwa optimisasi *hyperparameter* UMAP dan HDBSCAN mampu meningkatkan koherensi topik dibandingkan penggunaan parameter *default*.

Di sisi lain, *Grid Search* masih menjadi metode optimisasi *hyperparameter* yang paling umum digunakan karena mengevaluasi seluruh kombinasi *hyperparameter* pada ruang pencarian (*search space*) yang telah ditentukan sehingga mampu menemukan kombinasi terbaik dalam ruang pencarian tersebut. Namun, pendekatan ini memerlukan biaya komputasi yang tinggi ketika jumlah *hyperparameter* dan kandidat nilainya semakin besar. Meskipun berbagai metode optimisasi *hyperparameter* telah diterapkan pada BERTopic, penelitian yang menggunakan pendekatan metaheuristik berbasis *swarm intelligence*, khususnya *Artificial Bee Colony* (ABC), masih sangat terbatas. Selain itu, belum terdapat penelitian yang secara langsung membandingkan efisiensi *Grid Search* dan ABC dalam mengoptimalkan *hyperparameter* BERTopic pada kerangka pengujian yang sama. Oleh karena itu, penelitian ini bertujuan melakukan pemodelan topik opini publik di YouTube terkait isu pertumbuhan ekonomi Indonesia Kuartal-I 2026 menggunakan BERTopic, sekaligus membandingkan efisiensi optimisasi *hyperparameter* antara metode *Grid Search* dan algoritma *Artificial Bee Colony*.

2. METODE PENELITIAN

2.1. Pengumpulan dan Seleksi Data

Data penelitian berupa komentar publik pada video YouTube yang membahas pertumbuhan ekonomi Indonesia Kuartal-I Tahun 2026 pada periode 5–12 Mei 2026. Data dikumpulkan melalui web crawling menggunakan YouTube Data API v3 dengan bahasa pemrograman Python dan library *googleapiclient* menggunakan kata kunci “Pertumbuhan Ekonomi 5.61%”. Pemilihan periode pengumpulan data didasarkan pada waktu pengumuman resmi pertumbuhan ekonomi Indonesia Kuartal-I Tahun 2026 oleh Badan Pusat Statistik (BPS) pada tanggal 5 Mei 2026, sehingga rentang waktu tersebut merepresentasikan respons awal masyarakat terhadap informasi yang baru dipublikasikan. Batas akhir pengumpulan data ditetapkan pada tanggal 12 Mei 2026 karena pada tanggal tersebut proses analisis data mulai dilakukan.

Video yang dianalisis berasal dari 10 kanal YouTube, yaitu Ferry Irwandi, Raymond Chin,

Awalil Rizky, iNews, MetroTV, Liputan6, KompasTV, CNN Indonesia, CNBC Indonesia, dan NusantaraTV. Pemilihan kanal dilakukan secara *purposive* dengan mempertimbangkan keberagaman sumber informasi yang membahas isu pertumbuhan ekonomi, baik dari media massa maupun kreator konten individu. Kanal media massa dipilih karena berperan sebagai penyedia informasi resmi dan memiliki jangkauan audiens yang luas, sedangkan kanal kreator individu dipilih untuk merepresentasikan perspektif yang lebih personal dan interpretatif terhadap isu ekonomi. Pada periode pengumpulan data, Ferry Irwandi, Raymond Chin, dan Awalil Rizky merupakan kreator individu yang memiliki video terkait pertumbuhan ekonomi dengan tingkat keterlibatan (*engagement*) yang relatif tinggi. Sementara itu, tujuh kanal media massa yang dipilih juga merupakan kanal yang aktif memberitakan isu pertumbuhan ekonomi dan memiliki interaksi audiens yang tinggi. Pemilihan kedua kelompok kanal tersebut bertujuan untuk memperoleh gambaran yang lebih beragam mengenai sentimen, opini, dan cara masyarakat memaknai informasi terkait pertumbuhan ekonomi Indonesia.

Proses pengumpulan data menghasilkan 5089 komentar dari 16 video yang diunggah oleh 10 kanal YouTube tersebut. Data yang dikumpulkan meliputi isi komentar, nama pengguna, tanggal komentar, dan jumlah *likes*. Komentar YouTube dipilih karena mampu merepresentasikan respons, opini, dan persepsi publik secara spontan terhadap isu pertumbuhan ekonomi. Selanjutnya, komentar yang kosong, duplikat, serta tidak relevan dengan topik penelitian dihapus sehingga diperoleh dataset yang sesuai dengan tujuan penelitian.

2.2. Pra-proses Data

Pra-pemrosesan data dilakukan untuk membersihkan dan menyeragamkan teks sebelum pemodelan topik. Tahapan ini meliputi *cleaning* berupa penghapusan URL, emotikon, tanda baca, angka, karakter khusus, dan spasi berlebih agar teks lebih terstruktur serta mengurangi token yang tidak relevan terhadap pembentukan topik (Tarmizi, 2025). Emotikon dihapus karena lebih merepresentasikan ekspresi atau sentimen pengguna daripada informasi semantik. Selanjutnya dilakukan *case folding*, *tokenization*, *stopword removal* menggunakan pustaka Sastrawi dan *custom stopwords*, serta normalisasi untuk menyeragamkan kata tidak baku dan menggabungkan frasa penting menjadi satu token menggunakan tanda garis bawah (*underscore*), seperti *pertumbuhan_ekonomi* dan *ekonomi_indonesia* (Sembiring, 2025).

Tahap akhir berupa *text cleaning* lanjutan dengan menghapus data kosong, komentar duplikat, serta token yang memiliki panjang kurang dari tiga karakter. Penghapusan komentar duplikat bertujuan mengurangi pengaruh komentar berulang yang berpotensi bersifat spam atau tidak autentik sehingga korpus yang digunakan lebih merepresentasikan keragaman opini pengguna. Dengan demikian, data yang digunakan dalam analisis menjadi lebih bersih, konsisten, dan mampu menghasilkan representasi topik yang lebih akurat.

2.3. Eksplorasi Data

Eksplorasi data dilakukan untuk memberikan gambaran umum mengenai karakteristik komentar YouTube terkait pertumbuhan ekonomi Indonesia pada Kuartal-I tahun 2026. Tahapan ini mencakup analisis jumlah komentar dan video berdasarkan kanal untuk memetakan tingkat interaksi publik serta volume produksi konten, yang divisualisasikan menggunakan diagram batang. Selain itu, dilakukan juga perhitungan frekuensi kemunculan kata dengan metode *word counting* serta pembuatan *word cloud* pada keseluruhan korpus komentar hasil pra-pemrosesan guna menggambarkan kata-kata kunci dominan yang paling sering muncul dalam diskusi publik tersebut.

2.4. Pemodelan dengan BERTopic

BERTopic merupakan metode pemodelan topik berbasis *transformer* yang menggabungkan *semantic embedding*, reduksi dimensi, *clustering*, dan representasi topik untuk menghasilkan topik yang lebih kontekstual dan mudah diinterpretasikan (Grootendorst, 2022). Pada penelitian ini, komentar YouTube terlebih dahulu direpresentasikan menjadi vektor numerik menggunakan model IndoSBERT (*indobenchmark/indobert-base-p2*) yang mampu menangkap konteks bahasa Indonesia (Christianto, 2025). Selanjutnya, vektor tersebut direduksi dimensinya menggunakan UMAP (*Uniform Manifold Approximation and Projection*), yaitu teknik reduksi dimensi non-linear yang mempertahankan struktur lokal maupun global data dalam ruang berdimensi rendah (Ordun *et al.*, 2020; McInnes *et al.*, 2018).

Hasil reduksi dimensi kemudian dikelompokkan menggunakan HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*), yaitu metode *clustering* berbasis kepadatan yang mampu membentuk kluster secara otomatis sekaligus mendeteksi *noise* atau *outlier* (Ghiffary *et al.*, 2024). HDBSCAN dipilih karena tidak memerlukan penentuan jumlah kluster di awal, mampu mengakomodasi bentuk dan ukuran kluster yang beragam, serta sesuai untuk data teks hasil *embedding* yang umumnya memiliki distribusi tidak seragam dan mengandung komentar yang tidak secara jelas termasuk ke dalam topik tertentu. Selanjutnya, representasi topik dilakukan menggunakan CountVectorizer dan pembobotan *class-based Term Frequency-Inverse Document Frequency* (c-TF-IDF) untuk memperoleh kata-kata yang paling representatif pada setiap topik (Sadewa & Astuti, 2025), kemudian disempurnakan menggunakan *Maximal Marginal Relevance* (MMR) untuk menghasilkan kata kunci yang relevan, beragam, dan tidak redundan (Mawaridi, 2024).

2.5. Pengaturan Optimisasi Hyperparameter

a. Topic Coherence (NPMI)

Topic coherence digunakan untuk mengevaluasi tingkat keterkaitan semantik antar kata dalam suatu topik sehingga dapat menggambarkan seberapa baik topik tersebut dipahami dan diinterpretasikan. Dalam penelitian ini, jumlah topik optimal ditentukan menggunakan metrik *topic coherence* (Cv) yang berbasis *Normalized Pointwise Mutual Information* (NPMI) untuk mengukur kemiripan makna antar kata pada setiap topik. Nilai *coherence* yang semakin tinggi menunjukkan bahwa topik yang dihasilkan memiliki kualitas dan interpretabilitas yang semakin baik (Muhabbab & Rizki, 2024). Formula NPMI dapat dilihat pada Persamaan (2.1):

$$NPMI = \frac{\log\left(\frac{P(w_i, w_j) + \epsilon}{P(w_i)P(w_j)}\right)}{-\log(P(w_i, w_j) + \epsilon)} \quad (2.1)$$

Pada persamaan tersebut, w_i dan w_j merepresentasikan pasangan kata yang berasal dari daftar kata teratas (*top words*) pada topik yang sama, dengan $i, j = 1, 2, \dots, 10$. Sebagai contoh, apabila suatu topik memiliki kata-kata representatif seperti *pertumbuhan ekonomi*, *ekonomi indonesia*, *konsumsi*, *investasi*, dan *kuartal*, maka pasangan kata yang dievaluasi dapat berupa (*pertumbuhan ekonomi*, *ekonomi indonesia*), (*pertumbuhan ekonomi*, *konsumsi*), atau (*ekonomi indonesia*, *investasi*). Selanjutnya, $P(w_i, w_j)$ menunjukkan jumlah kemunculan bersama (*co-occurrence*) antara w_i dan w_j . Selanjutnya, $P(w_i)$ dan $P(w_j)$ menyatakan probabilitas kemunculan masing-masing kata dalam dokumen. Nilai probabilitas tersebut digunakan untuk mengukur tingkat keterkaitan semantik antar kata pada suatu topik, sehingga topik dengan kata-kata yang lebih sering muncul bersama cenderung memiliki nilai *coherence* yang lebih tinggi.

b. Topic Diversity (RDJ)

Topic diversity digunakan untuk mengukur tingkat keberagaman antar topik. Nilai *diversity* yang tinggi menunjukkan bahwa topik yang dihasilkan tidak saling tumpang tindih. Rumus perhitungan *Refined Diversity Jaccard* (RDJ) disajikan pada Persamaan (2.2):

$$RDJ = \frac{2}{n(n-1)} \sum_{i < j} \frac{|O_i \cap O_j|}{|O_i \cup O_j|} \quad (2.2)$$

Pada persamaan tersebut, O_i dan O_j merupakan himpunan kata dengan peringkat tertinggi pada topik ke- i dan topik ke- j , sedangkan n menyatakan jumlah total topik. Notasi $O_i \cap O_j$ menunjukkan irisan kedua himpunan, yaitu kata-kata yang muncul pada kedua topik secara bersamaan, sedangkan $O_i \cup O_j$ menunjukkan gabungan kedua himpunan, yaitu seluruh kata unik yang muncul pada salah satu atau kedua topik. *Jaccard similarity* digunakan untuk mengukur tingkat tumpang tindih antar topik berdasarkan kesamaan elemen yang dimiliki. Interpretasi keberagaman topik dilakukan menggunakan perhitungan $1 - RDJ$ di mana nilai yang semakin mendekati 1 menandakan bahwa topik yang dihasilkan semakin unik serta memiliki keberagaman semantik yang lebih tinggi.

c. Fungsi Objektif

Fungsi objektif (*objective function*) merupakan fungsi matematis yang digunakan untuk mengukur kualitas suatu solusi sehingga menjadi dasar dalam menentukan solusi terbaik. Nilai fungsi objektif akan dimaksimumkan agar sesuai dengan tujuan penelitian. Dalam penelitian ini, fungsi objektif yang digunakan disajikan pada Persamaan (2.3):

$$\max \text{ objective} = (0.7 \times \text{coherence}) + (0.3 \times \text{diversity}) \quad (2.3)$$

Pembobotan tersebut bertujuan agar model tidak hanya menghasilkan nilai objektif yang tinggi, tetapi juga menghasilkan topik yang mudah diinterpretasikan. Oleh karena itu, *coherence* diberikan bobot yang lebih besar (0.7) dibandingkan *diversity* (0.3) karena *coherence* mengukur keterkaitan semantik antar kata dalam suatu topik dan telah banyak digunakan sebagai indikator interpretabilitas topik yang berkorelasi dengan penilaian manusia (Mimno *et al.*, 2011; Lau *et al.*, 2014; Röder *et al.*, 2015). Pendekatan ini sejalan dengan Ali *et al.* (2023) yang menyatakan bahwa evaluasi model topik yang baik perlu mempertimbangkan koherensi semantik dan keberagaman topik untuk menghasilkan topik yang informatif dan tidak redundan.

d. Peubah Keputusan (*Decision Variables*)

Peubah keputusan (*decision variables*) dalam penelitian ini adalah *hyperparameter* $n_neighbors$ pada UMAP dan $min_cluster_size$ pada HDBSCAN, karena keduanya merupakan parameter yang paling berpengaruh terhadap pembentukan struktur kluster dan topik (Grootendorst, 2022). Parameter $n_neighbors$ mengatur keseimbangan antara struktur lokal dan global pada hasil reduksi dimensi UMAP (McInnes *et al.*, 2018), sedangkan $min_cluster_size$ menentukan ukuran minimum kluster pada HDBSCAN sehingga memengaruhi jumlah topik, ukuran kluster, dan dokumen yang dikategorikan sebagai *outlier* (McInnes *et al.*, 2017). *Hyperparameter* $n_components$ dan $min_samples$ tidak dioptimasi karena penelitian ini berfokus pada parameter yang paling berpengaruh terhadap pembentukan struktur kluster dan topik. Pembatasan peubah keputusan juga dilakukan untuk menjaga efisiensi komputasi dan mengurangi kompleksitas ruang pencarian.

e. Kendala (*Constraint*)

Constraint (kendala atau batasan) merupakan sekumpulan syarat yang membatasi ruang solusi (*feasible search space*), sehingga proses optimasi hanya dilakukan pada solusi yang memenuhi kriteria tertentu (Feurer & Hutter, 2019; Hutter *et al.*, 2019). Ruang pencarian optimisasi dibatasi oleh beberapa kendala, yaitu:

$$10 \leq n_{nb} \leq 30; \quad (2.4)$$

$$20 \leq mcs \leq 50; \quad (2.5)$$

$$K(x) \geq 2; \quad (2.6)$$

$$\gamma_{noise}(x) = \frac{N_{noise}(x)}{N} \leq 0.30; \quad (2.7)$$

Dengan n_{nb} nilai *hyperparameter* $n_neighbors$ pada UMAP, mcs nilai *hyperparameter* $min_cluster_size$ pada HDBSCAN, $K(x)$ jumlah topik yang terbentuk dari BERTopic berdasarkan kombinasi *hyperparameter* x , $N_{noise}(x)$ jumlah dokumen *noise* pada kombinasi *hyperparameter* x , N total dokumen dalam korpus, dan $\gamma_{noise}(x)$ proporsi dokumen yang diklasifikasikan sebagai *noise/outlier* oleh HDBSCAN terhadap total dokumen.

2.6. Optimisasi dengan *Artificial Bee Colony* (ABC)

Artificial Bee Colony (ABC) merupakan algoritma optimasi berbasis *swarm intelligence* yang terinspirasi dari perilaku koloni lebah madu dalam mencari sumber makanan. Algoritma ini pertama kali diperkenalkan oleh Dervis Karaboga dan Bahriye Basturk pada tahun 2007 dalam paper *A Powerful and Efficient Algorithm for Numerical Function Optimization: Artificial Bee Colony (ABC) Algorithm*.

Pada ABC terdapat tiga jenis lebah, yaitu *employed bee*, *onlooker bee*, dan *scout bee*. *Employed bee* bertugas mengeksplorasi sumber makanan yang telah diketahui sebelumnya serta mencari solusi baru di sekitar solusi yang dimiliki. Setiap solusi kemudian dievaluasi menggunakan nilai *fitness* yang merepresentasikan kualitas solusi. Dalam penelitian ini, nilai *fitness* diperoleh langsung dari nilai fungsi objektif (*objective function*). *Onlooker bee* memilih sumber makanan berdasarkan informasi *fitness* yang diberikan oleh *employed bee*, sedangkan *scout bee* bertugas mencari sumber makanan baru secara acak apabila solusi sebelumnya tidak mengalami peningkatan kualitas dalam sejumlah iterasi tertentu (Karaboga & Basturk, 2007).

Dalam algoritma ABC, setiap solusi direpresentasikan dalam bentuk vektor berdimensi D . Jika terdapat SN sumber makanan, maka solusi ke- i dapat dituliskan seperti pada Persamaan (2.8). Dalam penelitian ini, setiap solusi x_i merepresentasikan kombinasi *hyperparameter* BERTopic yang akan dioptimasi. Dimensi solusi yang digunakan adalah $D = 2$, yaitu: Parameter $n_neighbors$ digunakan pada algoritma dan parameter $min_cluster_size$ digunakan pada HDBSCAN.

$$x_i = (x_{i1}, x_{i2}) \quad (2.8)$$

Dengan D menyatakan jumlah peubah optimasi dan SN menyatakan jumlah sumber makanan dalam populasi. Representasi solusi ini digunakan untuk memudahkan proses eksplorasi pada ruang pencarian (Karaboga & Basturk, 2007). Tahap pertama dalam algoritma ABC adalah inisialisasi populasi. Pada tahap ini, seluruh solusi awal dibangkitkan secara acak di dalam batas pencarian yang telah ditentukan sebelumnya. Persamaan inisialisasi solusi dituliskan sebagai berikut:

$$x_{ij} = x_j^{min} + rand(0.1)(x_j^{max} - x_j^{min}) \quad (2.9)$$

Dengan x_j^{min} merupakan batas bawah peubah, x_j^{max} merupakan batas atas peubah, dan $rand(0.1)$ merupakan bilangan acak yang menyebar *uniform* antara 0 dan 1. Proses ini bertujuan menghasilkan populasi awal yang tersebar dalam ruang solusi sehingga meningkatkan peluang menemukan solusi global (Karaboga & Basturk, 2007).

Pada fase *employed bee*, setiap lebah pekerja akan menghasilkan solusi baru berdasarkan solusi sebelumnya. Proses pembentukan solusi baru dilakukan dengan membandingkan solusi saat ini terhadap solusi lain yang dipilih secara acak dalam populasi. Persamaan pembentukan solusi baru pada ABC dituliskan sebagai berikut:

$$v_{ij} = x_{ij} + \phi_{ij}(x_{ij} - x_{kj}) \quad (2.10)$$

Dengan v_{ij} merupakan solusi baru, x_{ij} merupakan solusi lama yang menyatakan menyatakan nilai peubah ke- j pada solusi ke- i , x_{kj} merupakan solusi pembanding dengan nilai peubah ke- j dari solusi lain ($k \neq i$) yang dipilih secara acak dari populasi sebagai pembanding dalam proses

pembentukan solusi baru, dan ϕ_{ij} merupakan bilangan acak pada interval $[-1, 1]$. Persamaan tersebut menunjukkan bahwa solusi baru diperoleh melalui modifikasi posisi solusi lama terhadap solusi lain di dalam populasi (Karaboga & Basturk, 2007).

Setelah solusi baru dihasilkan, kualitas setiap solusi dievaluasi menggunakan fungsi *fitness*. Dalam penelitian ini, fungsi *fitness* didefinisikan sama dengan fungsi objektif (*objective function*), sehingga proses optimasi dilakukan dengan memaksimalkan nilai fungsi objektif. Nilai *fitness* kemudian digunakan untuk menghitung probabilitas suatu solusi dipilih oleh *onlooker bee*. Probabilitas pemilihan solusi dihitung menggunakan Persamaan (2.11):

$$p_i = \frac{fit_i}{\sum_{n=1}^{SN} fit_n} \quad (2.11)$$

Dengan p_i merupakan probabilitas pemilihan solusi ke- i sedangkan fit_i merupakan nilai *fitness* solusi ke- i . Semakin tinggi nilai *fitness* suatu populasi, maka semakin besar peluang solusi tersebut dipilih oleh *onlooker bee* untuk dieksplorasi lebih lanjut (Karaboga & Basturk, 2007). Pada penelitian ini, nilai *fitness* diperoleh langsung dari nilai fungsi objektif yang dihitung untuk setiap kombinasi *hyperparameter*. Dengan demikian, *fitness*/fungsi objektif solusi ke- i dirumuskan sebagai berikut:

$$\max fit_i = (0.7 \times Coherence_i) + (0.3 \times Diversity_i) \quad (2.12)$$

Dengan *Coherence_i* merupakan nilai *topic coherence* dan *Diversity_i* merupakan nilai *topic diversity* yang dihasilkan oleh kombinasi *hyperparameter* ke- i . Pada fase *onlooker bee*, lebah pengamat memilih solusi berdasarkan probabilitas yang telah dihitung sebelumnya. Setelah solusi dipilih, *onlooker bee* kembali melakukan pencarian solusi baru menggunakan persamaan modifikasi yang sama seperti pada fase *employed bee*. Tahap ini berfungsi meningkatkan kemampuan eksplorasi algoritma terhadap daerah solusi yang memiliki *fitness* tinggi (Karaboga & Basturk, 2007). Persamaan (2.12) menunjukkan bahwa nilai *fitness* pada penelitian ini identik dengan nilai fungsi objektif, yaitu kombinasi linier berbobot antara *topic coherence* dan *topic diversity*.

Jika suatu solusi tidak mengalami peningkatan *fitness* dalam sejumlah iterasi tertentu atau melebihi parameter *limit*, maka solusi tersebut dianggap ditinggalkan (*abandoned*). Pada kondisi ini, *scout bee* akan menghasilkan solusi baru secara acak untuk menggantikan solusi lama. Tahap ini bertujuan menjaga kemampuan eksplorasi algoritma agar tidak terjebak pada solusi lokal (*local optimum*) (Karaboga & Basturk, 2007). Persamaan pembentukan solusi baru oleh *scout bee* dituliskan sebagai berikut:

$$x_{ij}^{new} = x_j^{min} + rand(0,1)(x_j^{max} - x_j^{min}) \quad (2.13)$$

Algoritma ABC memiliki dua mekanisme utama, yaitu eksplorasi dan eksploitasi. Mekanisme eksplorasi dilakukan oleh *scout bee* untuk mencari area baru dalam ruang pencarian, sedangkan mekanisme eksploitasi dilakukan oleh *employed bee* dan *onlooker bee* untuk memperbaiki solusi yang telah ditemukan sebelumnya. Keseimbangan antara eksplorasi dan eksploitasi menjadi faktor penting yang memengaruhi kemampuan algoritma ABC dalam menemukan solusi optimal global (Karaboga & Basturk 2007). Beberapa parameter penting dalam algoritma ABC meliputi jumlah sumber makanan (*SN*), nilai *limit*, jumlah iterasi maksimum (*Maximum Cycle Number/MCN*), dan jumlah dimensi peubah (*D*).

Parameter jumlah sumber makanan (*SN*), nilai *limit*, jumlah iterasi maksimum (*Maximum Cycle Number/MCN*), dan jumlah dimensi peubah (*D*) tidak dioptimasi karena mengakibatkan terjadinya *nested hyperparameter tuning* sehingga akan memberatkan komputasi. Oleh sebab itu, *hyperparameter* tersebut ditetapkan lewat prosedur *trial and error*. Nilai parameter tersebut ditetapkan berdasarkan rekomendasi Dervis Karaboga dan Bahriye Basturk (2007). Oleh karena itu, parameter-parameter tersebut dibuat konstan agar perbandingan dengan *Grid Search* tetap berfokus pada optimasi *hyperparameter* BERTopic.

2.7. Optimisasi dengan *Grid Search*

Grid Search merupakan metode *hyperparameter optimization* yang digunakan untuk mencari kombinasi *hyperparameter* terbaik dengan melakukan evaluasi terhadap seluruh kombinasi parameter yang telah ditentukan sebelumnya. Metode ini bekerja secara sistematis melalui pendekatan *exhaustive search*, yaitu mencoba semua kemungkinan kombinasi *hyperparameter* pada ruang pencarian (*search space*) yang tersedia. Menurut Pedregosa *et al.* (2011), *Grid Search* merupakan proses pencarian parameter secara menyeluruh (*exhaustive search over specified parameter values*) untuk memperoleh konfigurasi model terbaik.

Pada proses *Grid Search*, setiap *hyperparameter* terlebih dahulu ditentukan himpunan kandidat nilainya. Seluruh kandidat *hyperparameter* tersebut kemudian dikombinasikan membentuk ruang *hyperparameter* (*hyperparameter space*). Menurut Hutter *et al.* (2019), ruang *hyperparameter* dapat diinterpretasikan sebagai hasil perkalian Cartesien dari seluruh himpunan *hyperparameter* yang digunakan. Persamaan ruang *hyperparameter* dituliskan sebagai berikut:

$$\Lambda = \Lambda_1 \times \Lambda_2 \times \dots \times \Lambda_p \quad (2.14)$$

Dengan Λ merupakan ruang *hyperparameter*, Λ_i merupakan himpunan kandidat *hyperparameter* ke- i , dan p jumlah parameter. Pendekatan ini memungkinkan algoritma menemukan konfigurasi parameter terbaik secara sistematis, tetapi juga menyebabkan biaya komputasi meningkat seiring bertambahnya jumlah *hyperparameter* dan kandidat parameter (Bergstra & Bengio, 2012). Tujuan utama *Grid Search* adalah memperoleh kombinasi *hyperparameter* optimal dengan mengevaluasi seluruh kombinasi *hyperparameter* pada ruang pencarian berdasarkan fungsi objektif (*objective function*). Secara umum, optimasi *hyperparameter* dirumuskan sebagai pencarian kombinasi *hyperparameter* yang mengoptimalkan fungsi objektif (Feurer & Hutter, 2019). Pada penelitian ini, fungsi objektif dimaksimumkan sehingga masalah optimasi dapat dirumuskan sebagai berikut:

$$\lambda^* = \arg \max_{\lambda \in \Lambda} \text{fit}(\lambda) \quad (2.15)$$

Dengan λ^* merupakan kombinasi *hyperparameter* optimal, λ merupakan kombinasi *hyperparameter* pada ruang pencarian ($n_neighbors$ dan $min_cluster_size$), dan $\text{fit}(\lambda)$ merupakan nilai *fitness* yang diperoleh dari fungsi objektif, yaitu kombinasi berbobot antara *topic coherence* dan *topic diversity*, yang dimaksimumkan selama proses optimasi.

2.8. Perbandingan Metode Optimisasi

Model dengan *hyperparameter tuning* hasil optimisasi ABC dan *Grid Search* akan dievaluasi melalui metrik *topic coherence*, *diversity*, nilai fungsi objektif (yang dioptimalkan), serta waktu komputasi.

2.9. Visualisasi dan Interpretasi *Topic Modelling*

Topik yang dihasilkan divisualisasikan menggunakan *word cloud* untuk mempermudah interpretasi kata-kata dominan pada setiap topik. Selain itu, dilakukan analisis distribusi topik untuk memahami pola utama persepsi masyarakat pertumbuhan ekonomi Indonesia pada Kuartal-I tahun 2026. Interpretasi dilakukan berdasarkan kata-kata representatif yang muncul pada masing-masing topik sehingga dapat menggambarkan isu utama yang dibahas oleh masyarakat dalam komentar YouTube.

3. HASIL DAN PEMBAHASAN

3.1. Pra-pemrosesan Data

Pra-pemrosesan data bertujuan membersihkan dan menyeragamkan teks agar siap dianalisis. Tahapan yang dilakukan meliputi *cleaning text*, *case folding*, *tokenization*, *stopword removal*, normalisasi kata dan frasa, serta *text cleaning* untuk menghapus data duplikat dan data kosong. Selain itu, beberapa frasa penting digabungkan menggunakan tanda garis bawah (*underscore*), seperti *ekonomi_indonesia*, untuk mempertahankan makna selama proses analisis.


Tabel 3.1. Contoh teks komentar sebelum dan sesudah pra-pemrosesan data

Sebelum Pra-pemrosesan	Setelah Pra-pemrosesan
hallo warga sipil sekalian, selamat menonton ♥♥	halo warga sipil sekalian selamat menonton
Produk domestik bruto ...	produk_domestik_bruto ...
Kita semua terkecoh warga XD	terkecoh warga
@hamidabdul4817 baca lagi deh datanya..	hamdiabdul4817 baca lagi datanya


Pada tahapan ini juga dilakukan pendefinisian kustomisasi *stopword* serta *custom_slang* dan *slang* untuk mengakomodasi bahasa gaul (*slang*) pada teks komentar. Selain itu, dilakukan pendefinisian *shortword* untuk mengeliminasi kata yang berjumlah kurang dari empat huruf. Namun, proses ini akan dieksekusi setelah data melalui tahapan pra-pemrosesan dan *word embedding*.

3.2. Eksplorasi Data

Eksplorasi data dilakukan dengan menganalisis distribusi komentar dan video pada setiap kanal YouTube yang divisualisasikan menggunakan diagram batang. Meskipun CNBC Indonesia mengunggah jumlah video terbanyak (Gambar 3.1b), interaksi pengguna lebih didominasi oleh Liputan6, Ferry Irwandi, dan Raymond Chin yang memperoleh jumlah komentar tertinggi (Gambar 3.1a). Satu video dari kanal Ferry Irwandi dan Raymond Chin masing-masing menyumbang 2308 komentar (45.35%) dan 1392 komentar (23.56%) dari total komentar. Temuan ini menunjukkan bahwa perhatian publik di ruang digital lebih dipengaruhi oleh tingkat keterlibatan (*engagement*) dan daya tarik konten kreator dibandingkan banyaknya video yang dipublikasikan media konvensional.



Gambar 3.1. (a) Jumlah komentar terambil berdasarkan kanal



Gambar 3.1. (b) Jumlah video terambil berdasarkan kanal

Tabel 3.3. Representasi numerik teks


Teks Dokumen	<i>Embedding Vector</i> (768D)	UMAP <i>Reduction</i> (5D)
halo warga sipil	[-0.00205026, 0.0620244, 0.06432082	[0.7510428, 3.1953893,
sekalian selamat	... 0.04243084 -0.06270567	7.1836843, 3.4965181
menonton	-0.03009976]	0.29922897]

3.4. Optimasi *Hyperparameter Tuning*

Optimisasi *hyperparameter* dilakukan untuk memperoleh konfigurasi parameter yang menghasilkan topik dengan tingkat koherensi dan keberagaman yang optimal pada model BERTopic. Parameter yang dioptimasi meliputi ‘*n_neighbors*’ pada UMAP dan ‘*min_cluster_size*’ pada HDBSCAN karena keduanya berperan penting dalam proses reduksi dimensi dan pembentukan *cluster* sebagai dasar pembentukan topik. Ruang pencarian ditetapkan pada rentang [10, 30] untuk *n_neighbors* dan [20, 50] untuk *min_cluster_size*, dengan kualitas model dievaluasi menggunakan fungsi objektif yang mengombinasikan *coherence score* dan *diversity score*. Proses optimisasi dilakukan menggunakan dua pendekatan, yaitu *Artificial Bee Colony* (ABC) dan *Grid Search*.

a. Optimasi *Hyperparameter Tuning* dengan ABC

Artificial Bee Colony (ABC) digunakan untuk mengoptimasi *hyperparameter* BERTopic melalui proses pencarian solusi yang dilakukan secara iteratif. Mekanisme pencarian melibatkan tiga jenis lebah, yaitu *employed bee*, *onlooker bee*, dan *scout bee*, sehingga solusi optimal dapat diperoleh tanpa mengevaluasi seluruh kombinasi parameter seperti pada *Grid Search*. Dalam penelitian ini, algoritma ABC dikonfigurasi dengan 10 lebah, nilai *limit* sebesar 5, dan *patience* sebesar 5.

**Gambar 3.3.** Peta eksplorasi solusi ABC

Gambar 3.3 menunjukkan sebaran solusi yang dievaluasi oleh algoritma ABC selama proses optimisasi *hyperparameter*. Setiap titik merepresentasikan kombinasi *n_neighbors* (sumbu x) dan *min_cluster_size* (sumbu y), sedangkan warna menunjukkan nilai *objective* yang dihasilkan, dengan warna ungu merepresentasikan nilai *objective* yang relatif rendah dan warna hijau hingga kuning menunjukkan nilai yang lebih tinggi. Tanda bintang merah menandai solusi terbaik yang diperoleh selama proses optimisasi. Pada iterasi pertama, algoritma membangkitkan 10 solusi awal secara acak pada ruang pencarian yang telah ditentukan. Setiap solusi kemudian dievaluasi menggunakan fungsi objektif yang mengombinasikan *coherence score* dan *diversity score* serta menjadi sumber makanan (*food source*) awal bagi *employed bee*.

Berdasarkan Gambar 3.3, ABC hanya mengeksplorasi sebagian ruang pencarian yang dianggap menjanjikan sehingga tidak perlu mengevaluasi seluruh kombinasi parameter seperti pada

Grid Search. Pada iterasi berikutnya, *Employed Bee* (kotak) mengeksplorasi solusi di sekitar sumber makanan yang dimiliki dan menghasilkan kandidat solusi baru. Informasi kualitas solusi tersebut kemudian digunakan oleh *Onlooker Bee* (segitiga) untuk memilih dan mengeksploitasi wilayah dengan nilai *objective* yang tinggi. Sementara itu, *Scout Bee* (belah ketupat) membangkitkan solusi baru secara acak ketika suatu sumber makanan tidak mengalami perbaikan setelah sejumlah iterasi tertentu, sehingga membantu menjaga keberagaman pencarian dan mengurangi risiko algoritma terjebak pada optimum lokal.

Sebagian besar titik dengan nilai *objective* tinggi terkonsentrasi pada rentang $n_neighbors$ sekitar [20, 25[dan $min_cluster_size$ sekitar [35, 45]. Sebaliknya, titik-titik berwarna ungu yang tersebar di berbagai wilayah menunjukkan kombinasi parameter yang menghasilkan nilai *objective* relatif rendah sehingga tidak menjadi fokus eksploitasi lebih lanjut. Konsentrasi titik berwarna hijau hingga kuning pada wilayah tersebut menunjukkan bahwa algoritma secara bertahap mengarahkan proses pencarian menuju area solusi yang memiliki performa lebih baik. Proses ini berlangsung hingga algoritma mencapai kondisi konvergen pada iterasi ke-6.

Tabel 3.4. Ringkasan hasil optimisasi ABC *optimizer*

Parameter	Nilai
$n_neighbors\ optimal$	25
$min_cluster_size\ optimal$	33
Iterasi konvergensi	6
<i>Best objective</i>	0.6649
<i>Best coherence</i>	0.5689
<i>Best diversity</i>	0.8889
<i>Runtime</i>	1788,04 detik

Sebagaimana ditunjukkan pada Tabel 3.4, kombinasi $n_neighbors$ sebesar 25 dan $min_cluster_size$ sebesar 33 menghasilkan nilai fungsi objektif tertinggi sehingga dipilih sebagai konfigurasi *hyperparameter* optimal. Nilai *coherence score* yang diperoleh menunjukkan bahwa kata-kata penyusun dalam setiap topik memiliki keterkaitan semantik yang cukup baik, sehingga topik yang terbentuk relatif mudah dipahami dan diinterpretasikan. Di sisi lain, nilai *diversity score* sebesar 0.8889 mengindikasikan minimnya tumpang tindih kata representatif antar topik, yang menunjukkan tingkat keberagaman topik yang sangat baik.


b. Optimasi Hyperparameter Tuning dengan Grid Search

Grid Search digunakan sebagai metode pembandingan dengan melakukan pencarian secara sistematis pada seluruh kombinasi *hyperparameter* dalam ruang pencarian yang telah ditentukan. Setiap kombinasi parameter digunakan untuk membangun model BERTopic. Model yang dihasilkan kemudian dievaluasi menggunakan fungsi objektif guna memperoleh konfigurasi *hyperparameter* dengan kinerja terbaik.

Tabel 3.5. Ringkasan hasil optimisasi *Grid Search*

Parameter	Nilai
$n_neighbors\ optimal$	16
$min_cluster_size\ optimal$	36
Jumlah iterasi	651
<i>Best objective</i>	0.7101
<i>Best coherence</i>	0.5858
<i>Best diversity</i>	1.0000
<i>Runtime</i>	9916,26 detik

Sebagaimana ditunjukkan pada Tabel 3.5, algoritma *Grid Search* menghasilkan konfigurasi optimal berupa *n_neighbors* sebesar 16 dan *min_cluster_size* sebesar 36. Konfigurasi tersebut menghasilkan nilai fungsi objektif yang lebih baik dari hasil *ABC optimizer*. Nilai *coherence score* yang diperoleh mengindikasikan keterkaitan semantik yang cukup baik antar kata dalam setiap topik, sedangkan *diversity score* sebesar 1.0000 menunjukkan tidak adanya tumpang tindih kata representatif antar topik. Dengan demikian, topik yang dihasilkan tidak hanya memiliki konsistensi makna yang baik, tetapi juga mampu mempertahankan tingkat keberagaman yang tinggi.



Gambar 3.4. Heatmap fungsi objektif optimisasi *Grid Search*

Gambar 3.4 menampilkan *heatmap* nilai *objective* dari seluruh kombinasi *n_neighbors* dan *min_cluster_size* pada ruang pencarian *Grid Search*. Pada visualisasi ini, warna merepresentasikan besarnya nilai *objective*, di mana warna kuning menunjukkan nilai *objective* yang tinggi, warna hijau menunjukkan nilai sedang, sedangkan warna ungu hingga hitam menunjukkan nilai yang semakin rendah. Berbeda dengan peta eksplorasi *ABC optimizer*, *Grid Search* mengevaluasi seluruh kombinasi parameter sehingga distribusi nilai *objective* dapat diamati secara menyeluruh. Peningkatan nilai *n_neighbors* dan *min_cluster_size* cenderung menghasilkan area berwarna ungu tua hingga hitam yang mengindikasikan penurunan kualitas pembentukan topik akibat penggabungan klaster yang berlebihan. Area hitam dengan nilai *objective* nol menunjukkan kegagalan optimasi karena proporsi *outlier* melebihi 30%. Sebaliknya, kombinasi *n_neighbors* pada rentang [15, 22] dengan *min_cluster_size* menghasilkan area berwarna kuning hingga hijau yang menunjukkan performa lebih baik. Pola ini mengindikasikan bahwa wilayah parameter tersebut mampu menghasilkan keseimbangan yang lebih baik antara *coherence* dan *diversity*. Temuan ini menunjukkan bahwa *Grid Search* mampu mengeksplorasi seluruh ruang solusi, sedangkan *ABC* lebih selektif dalam menemukan wilayah parameter yang optimal.

c. Perbandingan Hasil Optimasi ABC dan *Grid Search*

Berdasarkan hasil pada Tabel 3.6, pendekatan *Grid Search* secara konsisten mengungguli metode *ABC* dalam aspek kualitas pemodelan topik. *Grid Search* berhasil mengunci nilai objektif tertinggi sebesar 0.7101, didukung oleh skor *coherence* (0.5858) dan *diversity* sempurna (1.000) yang mengonfirmasi bahwa topik yang terbentuk solid secara semantik sehingga mudah diinterpretasikan dan tidak saling tumpang tindih. Selain itu, *Grid Search* mampu menekan *outlier* hingga sebesar 3.48% dibandingkan dengan metode *ABC* yang menghasilkan *outlier* sebesar 5.42%.

Tabel 3.6. Perbandingan performa metode optimisasi

Metode	Objektif	<i>Coherence</i>	<i>Diversity</i>	<i>Outlier</i>	<i>Runtime</i> (detik)
ABC	0.6649	0.5689	0.8889	5.42%	1788.04
<i>Grid Search</i>	0.7101	0.858	1.000	3.48%	9916.26

Akan tetapi, *Grid Search* membutuhkan waktu eksekusi (*runtime*) hingga 9916.26 detik, yang mana menunjukkan beban komputasi yang berlebih, sejalan dengan temuan Hutter *et al.* (2019). Sebaliknya, metode ABC menunjukkan performa efisiensi komputasi yang baik, dengan mencatatkan waktu eksekusi sebesar 1788.04 detik (5.5 kali lebih cepat daripada *Grid Search*). Dengan margin nilai objektif yang tidak terlampaui jauh, temuan ini menunjukkan adanya *trade-off* krusial: *Grid Search* tetap menjadi pilihan utama untuk mengejar parameter optimal yang absolut (selama *search space* tidak terlalu besar), sementara ABC menawarkan alternatif solusi komputasi efisien untuk pengolahan data dalam jumlah besar.

3.5. Pemodelan Topik dengan *Hyperparameter Tuning Grid Search*


Hasil pemodelan topik dengan menggunakan *Grid Search* menghasilkan tiga topik utama, termasuk satu topik *outlier* (Topik -1), dengan distribusi yang sangat tidak seimbang di mana Topik 0 mendominasi sebagian besar dokumen. Topik 0 (Aktivitas Finansial) menjadi episentrum komentar dengan mendominasi volume percakapan sebesar 76.69% (3705 dokumen), di mana kemunculan kata kunci seperti "rupiah", "uang", "belanja", dan "pengeluaran" merefleksikan perhatian masif publik terhadap realitas ekonomi makro dan kondisi finansial domestik. Sementara itu, Topik 1 (Skeptisisme Publik) mencakup 19.98% (958 dokumen) dari total data, yang secara kontras mencerminkan pola komunikasi kritis, skeptis, dan pesimisme netizen di ruang digital terhadap fenomena pertumbuhan ekonomi melalui paparan kata kunci seperti "bohong", "asing", "mimpi", dan "halu" serta menunjukkan adanya pola komunikasi informal dalam data yang tersaji pada Tabel 3.7.

Tabel 3.7. Ringkasan *topic modelling Grid Search*

No	Topik	Label	Jumlah	Proporsi	Kata Kunci Utama
0	-1	<i>Outlier</i>	168	0.03	Merah, daya_beli, indonesia, ...
1	0	Aktivitas Finansial	3705	0.77	Rupiah, uang, belanja, pengeluaran...
2	1	Skeptisisme Publik	958	0.20	Bohong, asing, mimpi, halu...

3.6. Visualisasi Struktur Topik dengan UMAP

Visualisasi UMAP dengan model *Grid Search* pada Gambar 3.5 menunjukkan bahwa hasil topik modeling berhasil mengelompokkan dokumen ke dalam dua topik utama yang memiliki karakteristik berbeda. Topik 0 mendominasi sebagian besar dokumen dan membentuk *cluster* yang luas, mengindikasikan bahwa topik ini mencakup variasi pembahasan yang lebih beragam dibandingkan topik lainnya. Sementara itu, Topik 1 membentuk *cluster* yang lebih kecil, padat, dan cukup terpisah dari *cluster* utama, yang menunjukkan bahwa dokumen dalam topik tersebut memiliki kemiripan semantik yang tinggi. Jarak yang cukup jelas antara kedua *cluster* mengindikasikan bahwa model mampu membedakan kedua topik dengan baik dan menghasilkan pemisahan topik yang relatif jelas.



Gambar 3.5. Dokumen berdasarkan topik *Grid Search*

3.7. Distribusi Topik

Berdasarkan visualisasi pada Gambar 3.6 dan 3.7, Topik 0 didominasi oleh kata *rupiah*, *uang*, *belanja*, *pengeluaran*, dan *omongkosong*. Kata *rupiah* dan *uang* memiliki skor tertinggi dibandingkan kata lainnya, yang menunjukkan bahwa kedua kata tersebut merupakan representasi utama topik. Dominasi kata-kata tersebut mengindikasikan bahwa pembahasan dalam Topik 0 berkaitan dengan aspek ekonomi dan keuangan, khususnya mengenai perubahan nilai uang, aktivitas belanja, serta pengeluaran masyarakat.



Gambar 3.6. Distribusi topik *Grid Search*

Pada Topik 1, kata-kata yang memiliki skor tertinggi adalah *bohong*, *asing*, *mimpi*, *halu*, dan *suka*. Kata *bohong* dan *asing* memiliki kontribusi paling besar dalam pembentukan topik ini, sehingga dapat dianggap sebagai kata kunci utama. Keberadaan kata *bohong*, *asing*, dan *mimpi* mengonfirmasi skeptisisme dan pesimisme netizen di ruang digital terhadap pertumbuhan ekonomi Indonesia sebesar 5.61% pada Kuartal-I 2026. Selain itu, kemunculan kata-kata tersebut juga dapat merefleksikan adanya ketidakpercayaan sebagian masyarakat terhadap angka statistik yang dihasilkan oleh pemerintah, termasuk data yang dipublikasikan oleh Badan Pusat Statistik (BPS), sehingga muncul persepsi bahwa kondisi ekonomi yang dirasakan secara langsung belum sepenuhnya sejalan dengan data pertumbuhan ekonomi yang dilaporkan.



Gambar 3.7. *Word cloud* dan representasi tiap topik

4. KESIMPULAN

Penelitian ini berhasil menerapkan optimasi *hyperparameter* BERTopic menggunakan metode *Artificial Bee Colony* (ABC) dan *Grid Search* untuk menganalisis persepsi masyarakat terhadap pertumbuhan ekonomi Indonesia sebesar 5.61% pada Kuartal-I tahun 2026 berdasarkan komentar YouTube. Hasil penelitian menunjukkan bahwa kedua metode memiliki *trade-off* yang jelas; *Grid Search* menghasilkan metrik sedikit lebih unggul dengan *objective score* sebesar 0.7101, skor *coherence* 0.5858, *diversity* 1.0000, dan tingkat *outlier* terendah (3.48%), sedangkan ABC menghasilkan *objective score* 0.6649 dengan tingkat *outlier* 5.42%. Topik utama yang dihasilkan memiliki struktur yang konsisten dan kontras, yaitu Topik 0 (Aktivitas Finansial) sebesar 76.69% yang membahas perputaran rupiah serta kondisi finansial domestik, dan Topik 1 (Skeptisisme Publik) sebesar 19.83% yang merepresentasikan pandangan kritis dan keraguan netizen di kolom komentar. Meskipun demikian, ABC mampu mencapai kualitas solusi yang kompetitif tersebut dengan waktu komputasi sekitar 5.5 kali lebih cepat dibandingkan *Grid Search*. Temuan ini menunjukkan bahwa ABC merupakan alternatif yang efektif dan efisien untuk optimasi *hyperparameter* BERTopic karena mampu menghasilkan kualitas topik yang baik tanpa perlu mengevaluasi seluruh kombinasi parameter pada ruang pencarian. Penelitian selanjutnya dapat mempertimbangkan penggunaan ruang pencarian *hyperparameter* yang lebih luas. Selain itu, karena *hyperparameter* yang dioptimasi pada penelitian ini masih bersifat diskret, penelitian selanjutnya dapat mengeksplorasi kasus optimisasi *hyperparameter* yang bersifat kontinu untuk mengkaji lebih lanjut kemampuan algoritma *Artificial Bee Colony* dalam menemukan solusi yang lebih optimal.

DAFTAR PUSTAKA

- Ali, Y., Awwad, E., Al-Razgan, M., & Maarouf, A. (2023). Hyperparameter search for machine learning algorithms for optimizing the computational complexity. *Processes* 2023; 11: 349. <https://doi.org/10.3390/pr11020349>
- Badan Pusat Statistik. (2026). Pertumbuhan ekonomi Indonesia triwulan I-2026 (Berita Resmi Statistik No. 48/05/Th. XXIX). Badan Pusat Statistik.
- Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of machine learning research*, 13(2).
- Borčín, M., & Jose, J. M. (2024). Optimizing BERTopic: Analysis and reproducibility study of parameter influences on topic modeling. Dalam N. Goharian et al. (Eds.), *Advances in Information Retrieval. ECIR 2024. Lecture Notes in Computer Science*, vol. 14611 (hlm. 147–160). Springer. https://doi.org/10.1007/978-3-031-56066-8_14
- Chakkarwar, V. A., & Tamane, S. C. (2026). BERT-driven contextual topic modelling for enhanced financial news monitoring and analysis. *Journal of Integrated Science & Technology*, 14(4), 1561.
- Christianto, Y. (2025). Klasifikasi tingkat literasi digital menggunakan model SVM dan LSTM dengan ekstraksi fitur TF-IDF dan bert embedding (Doctoral dissertation, Universitas Islam Negeri Maulana Malik Ibrahim).
- Feurer, M., & Hutter, F. (2019). Hyperparameter optimization. In *Automated machine learning: Methods, systems, challenges* (pp. 3-33). Cham: Springer International Publishing.
- Ghiffary, G. G., Alifviansyah, K., Fitrianto, A., Erfiani, E., & Jumansyah, L. R. D. (2024). Perbandingan algoritma HDBSCAN dan agglomerative hierarchical clustering dalam klasterisasi pada data yang mengandung pencilan. *Jurnal Riset dan Aplikasi Matematika (JRAM)*, 8(2), 122-135.

- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv preprint arXiv:2203.05794.
- Haron, N. S., Jaafar, J., Aziz, I. A., Hasan, M. H., & Azam, M. H. (2025). Integrative hybrid metaheuristic algorithm for hyperparameter optimisation in pre-trained convolutional neural network models (I-HAHO). *International Journal of Advanced Computer Science & Applications*, 16(10).
- Hutter, F., Kotthoff, L., & Vanschoren, J. (2019). Automated machine learning: methods, systems, challenges. Springer.
- Karaboga, D., & Basturk, B. (2007). A powerful and efficient algorithm for numerical function optimization: Artificial bee colony (ABC) algorithm. *Journal of Global Optimization*, 39(3), 459–471. <https://doi.org/10.1007/s10898-007-9149-x>
- Lau, J. H., Newman, D., & Baldwin, T. (2014). Machine reading tea leaves: Automatically evaluating topic coherence and topic model quality. *Proceedings of the 14th Conference of the European Chapter of the Association for Computational Linguistics*, 530–539. <https://doi.org/10.3115/v1/E14-1056>
- Mawaridi, B. H. (2024). Sistem peringkasan teks berita berbahasa Indonesia menggunakan latent dirichlet allocation dan maximum marginal relevance (Doctoral dissertation, Universitas Islam Negeri Maulana Malik Ibrahim).
- McInnes, L., Healy, J., & Astels, S. (2017). hdbscan: Hierarchical density based clustering. *Journal of Open Source Software*, 2(11), 205. <https://doi.org/10.21105/joss.00205>
- McInnes, L., Healy, J., & Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. arXiv preprint arXiv:1802.03426.
- Mimno, D., Wallach, H., Talley, E., Leenders, M., & McCallum, A. (2011). Optimizing semantic coherence in topic models. In *Proceedings of the 2011 conference on empirical methods in natural language processing* (pp. 262-272).
- Muhabbab, A. Z. A., & Rizki, R. A. F. (2024, November). Topic modelling berbasis embedding pada komentar youtube. In *Seminar Nasional Official Statistics* (Vol. 2024, No. 1, pp. 873-884).
- Murugaraj, S., Lamsiyah, S., & Schommer, C. (2025). Automating historical insight extraction from large-scale newspaper archives via neural topic modeling. *arXiv preprint arXiv:2512.11635*. <https://arxiv.org/abs/2512.11635>
- Ordun, C., Purushotham, S., & Raff, E. (2020). Exploratory analysis of covid-19 tweets using topic modeling, umap, and digraphs. arXiv preprint arXiv:2005.03082.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in python. *The Journal of Machine Learning Research*, 12, 2825-2830.
- Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the space of topic coherence measures. *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*, 399–408. <https://doi.org/10.1145/2684822.2685324>
- Sadewa, W. F. N., & Astuti, L. G. (2025). Analisis sentimen terhadap ulasan aplikasi gojek menggunakan naive bayes classifier dengan BoW. *Jurnal Nasional Teknologi Informasi dan Aplikasinya*, 3(3), 669-676.
- Sembiring, A. R. (2025). Sentiment analysis dan topic modeling pada tweet bahasa Indonesia mengenai Pemilihan Umum 2024 (Doctoral dissertation, Universitas Islam Indonesia).
- Tarmizi, V. C. (2025). Klasifikasi sentimen masyarakat terhadap Kaesang Pangarep pada media sosial twitter/X menggunakan MLP classifier dengan fitur fasttext. *TIN: Terapan Informatika Nusantara*, 6(7), 1105-1114.
- Terragni, S., Fersini, E., Galuzzi, B. G., Tropeano, P., & Candelieri, A. (2021, April). OCTIS: Comparing and optimizing topic models is simple!. In *Proceedings of the 16th conference of the European chapter of the association for computational linguistics: system*

demonstrations (pp. 263-270).

Yang, L., & Shami, A. (2020). On hyperparameter optimization of machine learning algorithms: Theory and practice. *Neurocomputing*, 415, 295–316.
<https://doi.org/10.1016/j.neucom.2020.07.061>